

핵심 키워드 자동 추출과정 (TextRank)

기존 5문항 키워드 리스트(정답_키워드)는 사람이 임의로 고른 것이라 지적을 받았고, 아래 방식으로 다시 만들어야 함

문제점 (교수님 피드백)

기존 방식: 정답_키워드를 손으로 2~3개씩 지정하고, 통과 기준을 "1개 이상"으로 설정함.

문제: 사용자가 사건 이름 하나만 말해도("을사조약"만 말해도) 통과되어버림. 서술 능력을 전혀 측정하지 못함.

해결 방향

키워드를 사람이 고르지 말고, 키워드를 알고리즘으로 자동 추출해서 객관성을 확보하고, 통과 기준도 더 엄격하게(통과컷을 올려야함) 바뀌어야 함

처리 과정

1단계: 원문 텍스트 확보

각 문항(사건)에 대한 설명 텍스트를 한능검 공식 홈페이지에서 확보.

- 한능검 공식 홈페이지의 해설/설명문 크롤링
- 만약 해설문이 없는 문제의 경우, 기출문제에서 해당 문항의 제시문과 사료로부터 텍스트원문 추출

2단계: 형태소 분석 (명사 추출)

- 형태소 분석기 사용 (터미널에서 Mecab실행)

- 원문 텍스트에서 명사만 추출 (형태소 분석기가 문장의 각 형태소마다 품사태그를 붙여줬고, 그 중 명사태그만 남기는 걸로 설정함)

3단계: TextRank로 핵심 키워드 순위 매기기

- 추출된 명사들을 엑셀파일로 리스트업

-언어모델에서, "각 문항마다 알고리즘에 입력할 코드를 작성해줘" 라고 지시

그리고 5문항이니까 코드 5개 생김, 그걸 알고리즘에 넘김

(터미널에서 텍스트랭크를 실행하고, 거기서 알고리즘을 돌림(코드로 실행해야해서...))

- 문항(사건)별로 상위 5개 키워드를 순위와 함께 추출

4단계: 키워드 세트 및 통과 기준 재구성

-결과를 확인하니, 너무 일반적의미로 사용되는 단어가 고득점 (조선, 일본 이런 단어)

언어모델에서, 공통일반어(문항빈도 3회이상)를 배제하게 하는 코드 작성하고 재실행

- 분류된 고유명사 중, 인물명만 분류(언어모델에서 코드작성 > 실행), 상위랭크 인물 채택
- 연도고정: 알고리즘상 순위가 낮으나 내용학습상 필수라, 키워드 5개중 1칸을 연도로 고정
- 통과 기준을 상향 조정: 기존 "1개 이상" → **"5개 중 3개 이상"** 등으로 강화
- 텍스트랭크로부터 받은 키워드와 이후 바뀐 최종키워드를 구분하기 위해

코드입력 전 처음에 텍스트랭크가 뽑아준 핵심키워드는 순수 텍스트랭크. (일단 json파일로 다운받아두기는 함)

이후에 수정한건 최종 핵심 키워드 로 구분하여 표를 작성함