

AI-INTEGRATED DESIGN

E.

리뷰 기반 UX 분석 및 UI 디자인

리뷰에서 답을 찾아주고 근거와 신뢰도까지 보여주는 스터디카페 Q&A 챗봇

CONTENTS

목표: 문제 정의부터 최종 프로토타입까지의 진행 과정을 순서대로 정리한다.

01 UX 문제 정의

리뷰로는 방문 전 판단이 어렵다

02 사용자 및 사례 조사

요약형 서비스와의 차별점 찾기

02-1 선행 연구 · 02-2 리서치 결과 · 02-3 방식 비교

03 클래스 선정 및 근거 도출

선행 연구 · 데이터 기반 클래스 선정

04 데이터 수집 및 라벨링

300문장 · 5개 클래스

05 AI 모델 학습 및 검증

3모델 다수결 · 문장 분절

05-1 Input Mapping Table

06 UX 시나리오 설계

질문에서 답변까지의 흐름

07 AI 피드백 전략 설계

6개 상태와 확정 기준값

08 UI / 인터페이스 디자인

7개 화면과 컴포넌트

08-1 상태 판정 · 08-2 Interaction · 08-3 Screen Flow

09 AI-UI 연동 구현

React 프로토타입 구현

10 사용성 평가 및 개선

발견한 문제와 개선안

01. UX 문제 정의

목표: AI가 해결할 사용자 경험 문제를 정의한다.



PROJECT GOAL

리뷰를 다 읽지 않아도
질문 한 줄로 답을 얻고,
그 답의 근거 리뷰 수와
의견 갈림 여부까지 함께 보여주는
리뷰 기반 Q&A 챗봇

단순 요약봇이 아니라
“판단을 도와주는 도구”

1 UX Problem

- 리뷰가 길고 흩어져 있어 방문 전 판단이 어렵다
- “언제 붐비는지”, “시설이 어떤지”가 한눈에 안 보인다
- 궁금한 게 구체적일수록 검색어를 정하기 어렵다
- 요약만 봐서는 그 말의 근거를 확인할 수 없다

2 Target User

- 스터디카페 방문 전 정보를 확인하려는 사용자
- 시험기간 자리 · 소음을 미리 확인하려는 학생
- 운영시간 · 주차 같은 사실 정보를 빠르게 알고 싶은 방문자

3 Context

- 네이버 플레이스에 리뷰는 이미 충분히 쌓여 있다
- 요약 · 태그형 서비스는 많지만 질문형은 드물다
- 같은 항목이라도 사람마다 의견이 갈리는 경우가 있다

사용툴

- ✓ ChatGPT · Claude · Gemini (분류 · 교차검증)
- ✓ Figma (UI / 인터페이스 디자인)
- ✓ Claude Code (React 프로토타입)
- ✓ 크롬 개발자도구 (리뷰 수집)
- ✓ Framer (연동 시도 · 중단)

02. 사용자 및 사례 조사

목표: 기존 서비스의 정보 제공 방식과 한계를 조사한다.

산출물 · 기존 서비스 조사표

국내 서비스

네이버 키워드 리뷰 태그

- 방문자가 고른 키워드 · 빈도수를 항목별로 노출
- 몇 명이 왜 그렇게 느꼈는지는 알 수 없음
- 단디스터디카페 전농점 기준 키워드 태그 **14종** · 최다 태그 '조용해요' **63건**

네이버 지도 앱 직접 조사 · 2026.07.26

네이버 AI 브리핑 (문단 요약)

- 하이퍼클로바X로 최신 리뷰를 한 문단 요약
- 요약 근거가 된 리뷰를 특정할 수 없음
- 도입 후 체류시간 **10.4% ↑** · 클릭률 **27.4% ↑** · '더보기' 탭 **137% ↑** · 예약 **8% ↑**

2025.06 도입 · 연합뉴스 2025.08.21

야놀자 리뷰 시스템

- 별점 · 클래스별 요약 중심
- 의견이 갈릴 때 갈렸다고 알려주지 않음
- 숙소 1곳 기준 평가 항목 **6종** · 리뷰 **248건** 집계, 갈림 표기 **0건**

야놀자 앱 직접 조사 · 2026.07.26

해외 서비스

Google Places · AI 리뷰 요약

- 리뷰 주제를 추출해 자동 요약
- 근거는 "전체 리뷰 목록" 링크 하나뿐
- 리뷰 기여자 **3억** 명 · 등록 장소 **2.5억** 개 규모 데이터 기반 · Gemini 요약

Google Maps Platform 공식 문서 · 2025 정식 출시

Google Ask Maps (대화형)

- 자연어 질문에 장소 추천 · 설명 생성 (2026.03, Gemini 기반)
- 답변은 완성된 문단, 근거 리뷰 비율은 제시하지 않음
- 월 **20억** 명 사용 · 하루 **1억** 건 갱신되는 지도에 질문형 인터페이스 도입

2026.03.12 미국 · 인도 출시 · Google 공식 블로그

조사 결과 정리

국내 3종 서비스

- 키워드 태그 · 문단요약 · 별점집계 = 모두 비접촉 요약형
- 세 가지 모두 근거 원문과 연결되지 않음
- 네이버만 도입 효과를 수치로 공개 · 나머지는 직접 조사로 확인

해외 2종 서비스

- Ask Maps는 질문엔 답하지만 근거 비율은 없음
- 인터페이스만 다를 뿐 근거 구조는 동일함

공통 결론

- 5개** 서비스 모두 결과는 주지만 근거는 안 줌
- Ask Maps조차 근거 리뷰 비율은 제시하지 않음

다섯 서비스 모두 요약은 잘하지만, 요약 내용의 근거가 부족했다.

02-1. 선행 연구 조사

목표: 리뷰 기반 Q&A와 근거 제시에 대한 선행 연구를 검토한다.

산출물 · 선행 연구 요약

커머스 · QA 연구

MoQA (McAuley & Yang, 2016)

- 리뷰 한 편 한 편을 질문에 답해 줄 '증인'으로 보고, 질문과 관련이 깊은 리뷰일수록 답에 더 크게 반영한다
- '리뷰를 근거로 질문에 답한다'는 문제를 처음으로 정의한 연구
- 질문 **140만** 건 · 리뷰 **1,300만** 건 규모의 데이터로 검증 (WWW '16, 625–635)

Wan & McAuley (2016)

- 같은 질문이라도 사람마다 답이 다를 수 있다는 점을 확인하고, 답이 어떻게 갈리는지까지 모델에 담았다
- 답이 갈리는 상태를 숨기지 않고 그대로 보여줘야 한다는 근거
- 질문 **80만** 건 · 답변 **310만** 건 규모의 데이터셋 구축 (IEEE ICDM 2016, 489–498)

References

McAuley, J., & Yang, A. (2016). Addressing Complex and Subjective Product-Related Queries with Customer Reviews. WWW '16, 625–635.

Wan, M., & McAuley, J. (2016). Modeling Ambiguity, Subjectivity, and Diverging Viewpoints in Opinion QA Systems. IEEE ICDM 2016, 489–498.

Li, H., & Chaturvedi, S. (2024). Rationale-based Opinion Summarization. NAACL-HLT 2024, 8267–8285.

Amershi, S., et al. (2019). Guidelines for Human-AI Interaction. CHI 2019, 1–13. DOI: 10.1145/3290605.3300233

요약 · 가이드라인 연구

RATION (Li & Chaturvedi, 2024)

- 의견 요약 + 근거 리뷰 원문(rationale)을 함께 출력, **4개** 조건으로 근거 선별
- 사람 평가에서 유용성·일관성이 기존 요약보다 높게 나옴
- 단, 길이 제약으로 정보 포괄성(informativeness)은 오히려 낮아지는 트레이드 오프 존재

Amershi et al. (2019) · CHI — 우리 화면에 적용한 3개 지침

- G11 "왜 그렇게 답했는지 알 수 있게 하라" → 근거 리뷰 원문 카드
- G2 "얼마나 자주 틀릴 수 있는지 알려라" → 근거 개수 뱃지 · **70:30** 비율 바
- G10 "불확실하면 범위를 좁혀라" → 정보부족 · 이해실패 상태 **2종**
- 18개** 지침 · 실무자 49명이 AI 제품 **20개** 검증 → **785개** 사례 중 위반 **277건 (35%)**

시사점 정리

질문 응답 관점

- 리뷰를 근거로 답하는 태스크 자체가 선행 연구로 존재함 (MoQA)
- 답이 갈리는 것이 정상이라는 전제도 이미 연구됨 (Wan & McAuley)

근거 제시 관점

- 근거를 붙인 요약이 근거 없는 요약보다 유용성이 높음 (RATION)
- 단, 길이 제약으로 포괄성이 낮아지는 트레이드오프는 그대로 남음

UI 설계 관점

- G11: 왜 그렇게 답했는지 설명 가능해야 함
- G10: 불확실하면 범위를 좁혀라 → 근거 미달 시 정보부족 처리
- G2: 얼마나 자주 틀릴 수 있는지 알려라 → 근거 비율로 노출
- MoQA·Wan & McAuley는 커머스 데이터 연구 → 도메인이 아니라 태스크 정의를 인용

근거를 붙이면 유용해지고, 갈림을 인정하면 신뢰가 높아지고, 설명가
능하면 안심된다는 결론을 얻었다.

02-2. 리서치 결과 정리

목표: 조사 결과가 "근거 필요형 Q&A" 방향으로 이어진 과정을 정리한다.

산출물 · 리서치 결과 정리

인사이트 1~3

인사이트 1 · 요약 기능은 이미 검증됐다

- 체류시간 **10.4%** ↑ · 클릭률 **27.4%** ↑ · "더보기" **137%** ↑ · 요약 **8%** ↑ (연합 뉴스 2025.08)
- 리뷰를 대신 요약해주는 기능 자체의 수요는 확실함
- ⇒ 결론: 요약은 이미 검증된 기능, 차별점은 다른 곳에 있다

인사이트 2 · 그런데 전부 요약만 있었다

- 네이버 AI브리핑 · Google 리뷰요약 · 야놀자 모두 결과만 주고 근거 원문과 연결 안 함
- Google이 근거로 주는 것도 "전체 리뷰 목록" 링크 하나뿐
- ⇒ 결론: 근거 원문 연결이 공통적으로 빠져 있다

인사이트 3 · 대화형도 등장했지만 근거는 그대로 없다

- Ask Maps 2026.03.12 미국·인도 출시 → 월 **20억** 사용자 규모 지도에 질문형 도입
- 차별점은 "질문 가능" 여부가 아니라 "근거 신뢰도 노출" 여부
- ⇒ 결론: 그냥 답변만으로는 부족하고, 근거에 신뢰성이 있어야 한다

인사이트 4~6

인사이트 4 · 근거를 붙이면 실제로 더 유용하다

- RATION(2024) 사람 평가에서 근거 제시 요약이 유용성·일관성 더 높음
- 단, 길이 제약으로 정보 포괄성은 다소 낮아지는 문제점 존재
- ⇒ 결론: 근거는 붙이되, 포괄성 저하는 별도로 대비해야 한다

인사이트 5 · 의견 갈림은 감춰야 할 오류가 아니다

- Wan & McAuley(2016): 리뷰 기반 QA는 "정답 하나"를 전제하지 않음
- 갈림을 감추지 않고 비율과 원문으로 보여주는 방향을 채택
- ⇒ 결론: **70:30** 같은 기준으로 갈림 자체를 먼저 고지한다

인사이트 6 · 설계 원칙을 UI 디자인에 반영한다

- Amershi et al.(2019) G11·G2·G10을 화면 요소로 구현
- 근거 표시 · 신뢰도 사전 고지 · 불확실 시 범위 축소로 구현
- ⇒ 결론: 근거 필요형 Q&A의 UI 원칙이 여기서 확정된다

최종 방향

기존제품의 문제점

- 결과만 주는 요약형 인터페이스
- 의견 갈림을 감추는 집계 방식

이 프로젝트의 차별점

- 질문에 즉시 답하는 대화형 구조 (Ask Maps에서 확인된 수요)
- 근거를 함께 보여주는 방식 (RATION에서 확인된 유용성)

최종 확정

- 근거 리뷰 개수 · 원문 · **70:30** 갈림 비율을 답변마다 노출
- 근거가 기준 미달이면 정보부족으로 응답
- 커머스 QA 연구(MoQA)의 태스크 정의를 리뷰 도메인에 적용

요약해서 보여주는 봇이 아니라, 질문하면 근거와 함께 답해주는 챗봇
— 6단계 조사 끝에 확정된 방향이다.

02-3. 정보 제공 방식 비교와 차별점 정리

목표: 방식별로 사용자가 얻는 것과 근거 확인 가능성을 비교하고, 본 프로젝트의 처리를 정한다.

방식 · 대표 사례	사용자가 얻는 것	근거 확인 가능성	남는 한계	본 프로젝트의 차별점
키워드 태그 집계 네이버 키워드 리뷰	인기 키워드와 언급 수	불가 — 원문과 연결 절단	항목이 고정되어 구체적 질문에 대응 못 함	→ 자연어 질문을 그대로 받아 처리
문단 요약 네이버 AI 브리핑	압축된 한 문단 설명	불가 — 근거 리뷰 특정 불가	요약 문장별 근거를 짚을 수 없음	→ 수집된 리뷰에서 질문과 겹치는 부분만 좁혀 근거로 제시
문단 요약 Google Places AI 요약	주제 테마 요약	제한적 — 전체 리뷰 목록 링크뿐	답변과 원문이 1:1 로 붙지 않음	→ 답변마다 "리뷰 N개 중 M개 근거"로 명시
별점 · 항목 요약 야놀자	항목별 평점 요약	불가 — 직접 원문 검색 필요	의견이 갈려도 갈렸다고 알리지 않음	→ 70:30 기준으로 갈림을 먼저 고지 + 비율 바
대화형 어시스턴트 Google Ask Maps (2026.03)	질문에 대한 완성형 답변	불가 — 개수 · 비율 미제시	근거가 적어도 단정적으로 답함	→ 근거 미달 시 답하지 않고 정보부족으로 처리

기존 다섯 방식과의 차별점 — 근거 개수 · 원문 · 갈림 비율을 답변마다 함께 준다.

본 프로젝트가 모든 답변에 기본 탑재하는 것 → ① 근거 리뷰 개수(N개 중 M개) ② 근거가 된 리뷰 원문 카드 ③ 긍·부정 비율과 갈림 여부

03. 클래스 선정 및 근거 도출

목표: 어떤 입력을 사용할지 결정하고, 선행 연구와 수집 데이터로 그 근거를 제시한다.

산출물 · 클래스 정의 · 선정 근거

선정 기준 : 학습공간 연구에서 중요도가 높게 나온 항목 + 실제 리뷰에서 반복 언급되는 주제

선행 연구의 공간 속성 순위와 초기 수집한 리뷰 **240문장**의 언급 분포를 교차 확인해 **4개**를 정했고, 자체 테스트에서 답변 불가가 발견된 운영시간을 추가해 **5개**가 됐다.

입력 클래스 정의 및 선정 근거

클래스	설명	선정 근거	질문 유형 · 최소 근거
혼잡도	시간대별로 붐비는 정도	Cha & Kim(2015) 공간 속성 중요도 3위 'Crowdedness' · 자체 리뷰 데이터 44건(18.3%)	맥락형 · 리뷰 3개 이상
소음	소음 수준과 조용한 정도	Cha & Kim(2015) 중요도 2위 'Noise level' · 자체 리뷰 데이터 47건(19.6%)	맥락형 · 리뷰 3개 이상
시설	콘센트 · 주차 · 화장실 등 시설물 상태	Cha & Kim(2015) 1·4·5위(공간 규모·좌석 편안함·청결) 통합 · 자체 리뷰 데이터 102건(42.5%)	질문에 따라 사실형 / 맥락형
몰입환경	조명 · 분위기 · 집중도	문헌 상위 5위 밖 · 자체 리뷰 데이터에서는 47건(19.6%) 확인돼 별도 클래스로 유지	맥락형 · 리뷰 3개 이상
운영정보	영업시간 · 심야 운영 · 휴무	문헌 근거 없음 · 자체 테스트에서 '몇 시까지 해?' 답변 불가가 발견돼 사실형 질문으로 추가	사실형 · 리뷰 1개

4개 클래스로 초기 수집 240문장 전부 분류됨 — 미분류 0건

선행 연구 · 학습공간 속성 중요도

학습공간 속성 **18개**를 정의하고 학생 252명 설문으로 중요도를 매긴 연구

상위 **5개** : ① 공간 규모 ② 소음 수준 ③ 혼잡도 ④ 좌석 편안함 ⑤ 청결

→ 상위 **5개** 전부가 본 프로젝트의 혼잡도 · 소음 · 시설 **3개** 클래스에 대응

Cha, S. H., & Kim, T. W. (2015). What matters for students’ use of physical library space? The Journal of Academic Librarianship, 41(3), 274–279.

언급 분포 집계 방법

1. 수집

네이버 플레이스 스터디카페 리뷰를 크롬 개발자도구 (F12) 콘솔로 텍스트만 추출 (상세는 04)

2. 정리

문장 단위로 나눠 엑셀 시트로 옮김 — [문장 / 클래스 / 톤] 3컬럼 표로 관리 (초기 **240문장**)

3. 라벨링

각 문장의 클래스와 톤(긍정 / 부정)을 판단

4. 집계

클래스별 건수를 세어 전체 대비 비율 비교

5. 검증

같은 문장을 GPT · Claude · Gemini 3모델에 독립 분류시켜 라벨을 교차 확인

04. 데이터 수집 및 라벨링

목표: AI 모델 학습을 위한 데이터를 구축한다.

CLASS & LABELING · 최종 데이터 구성

혼잡도	60문장 긍정 36 · 부정 24	시간대별 자리 상황 · 시험기간 · 예약 · 대기
소음	60문장 긍정 28 · 부정 32	방음 · 통화 소리 · 백색소음 · 매장 음악
시설	60문장 긍정 36 · 부정 24	콘센트 · 주차 · 화장실 · 좌석 · 요금 · 관리
몰입환경	60문장 긍정 34 · 부정 26	조명 · 분위기 · 인테리어 · 집중도
운영정보	60문장 긍정 28 · 부정 32	영업시간 · 심야 운영 · 휴무 · 할증

총 300문장 · 5개 클래스

초기 수집 240문장으로 4개 클래스를 정한 뒤, 운영정보 클래스를 추가하고 보강 수집해 클래스당 60문장씩 총 300문장으로 맞췄다. 이 300문장을 372조각으로 분절해 3모델 다수결로 라벨을 확정했다.

수집 · 분절 · 라벨링 진행 방법

1. 수집

네이버 플레이스 리뷰를 크롬 개발자도구(F12) 콘솔로 텍스트만 뽑아내고, 곧바로 표로 옮겨 관리한다.

2. 문장 분절

한 문장 안에 서로 다른 질문에 답할 정보가 **2개** 이상이면 그 지점에서 자른다. 연결어미(-고 / -해서 / -는데 / -지만 / -면서 / -니까)를 기준으로 판단한다.

3. 자르지 않는 경우

뒷조각이 “좋다 / 별로다” 같은 일반 감상어뿐이거나, 앞조각 없이는 의미가 성립하지 않거나, 두 조각이 동어반복일 때는 자르지 않는다.

4. 판별 테스트

“이 조각만 따로 떼어놓아도 사용자 질문에 대한 독립적인 답이 되는가?”

5. 원문 보존

분절은 내부 처리용이다. 챗봇이 원문 펼침에서 보여주는 문장은 항상 분절 전 원본 그대로 사용한다.

05. AI 모델 학습 및 검증

산출물 · 모델 일치율 · 교차검증 결과표

목표: 세 LLM이 같은 리뷰의 긍/부정 톤을 비슷하게 판단하는지 검증한다. (E 트랙은 별도 학습 대신 **3개** LLM 교차검증 + 다수결로 대응)

교차검증 진행 과정

검증 목적 · 톤 판단 일관성

톤 판단을 하나의 모델로 학습시키면 해당 모델의 의견만 남는다. 같은 문장을 GPT · Claude · Gemini에 각각 교차검증하여 세 모델의 긍/부정 판단이 갈리는지 확인한다.

분류 상태 고정

분절은 Claude가 1회 수행한 뒤 고정한다. 세 모델에는 이미 나뉜 분절문장의 클래스와 톤을 분류하도록 프롬프트에 명시했다. 분절 자체는 검증 대상이 아니다.

1차 결과 · 문장 단위

300문장 · 톤 만장일치 **100%**(갈림 **0건**) · 클래스 만장일치 **270개(90.0%)** · 판단보류 **0건**

원인 분석 · 톤 판단에서 판단 갈림 발생

톤은 세 모델이 전부 일치했고, 갈린 **30건**은 대부분 시설 ↔ 몰입환경 경계였다. 한 문장 안에 [물리적 사실]과 [그로 인한 주관적 경험]이 함께 있었던 것이 문제였다.

판단 갈림 개선 · 의미 단위 분절

클래스 갈림을 줄이기 위해 문장을 의미 단위로 쪼갠 뒤 조각별로 다시 분류시켰다 (**300문장** → **372조각**). 분절 방식을 검증한 것이 아니라 분류 입력을 다듬은 단계다.

2차 결과 · 조각 단위

372조각 · 톤 만장일치 **100%**(갈림 **0건**) · 클래스 만장일치 **346개(93.0%)** · 판단보류 **0건**

교차검증 결과 비교

구분	대상 수	톤 일치율	클래스 일치율	갈림의 성격
1차 · 문장 단위	300문장	100% (갈림 0)	90.0% (270개)	갈림 30건 전부 클래스 축
2차 · 조각 단위	372조각	100% (갈림 0)	93.0% (346개)	갈림 26건 전부 클래스 축

판단보류(세 모델 전부 불일치)는 1 · 2차 모두 **0건**

남은 경계 모호 사례 · 2차 갈림 26건은 전부 클래스 분류에 대한 것이다.

표현 유형	갈리는 클래스 (톤은 세 모델 모두 일치)
“쾌적하다”	몰입환경 ↔ 시설
“분위기가 조용하다” / 음악 관련	몰입환경 ↔ 소음
“원하는 자리 선택 가능”	시설 ↔ 혼잡도

톤 일치율 100% · 클래스 불일치 10.0% → 7.0%

3개의 LLM으로 교차검증해서 다수결로 정한 결과, 세 모델의 긍/부정 판단은 1 · 2차 모두 완전히 일치해 톤 라벨을 그대로 확정할 수 있었다. 대신 갈린 건 전부 클래스 경계였고, 의미 단위 분절로 그 비율을 10.0%에서 7.0%까지 줄였다. 답변 로직은 브라우저에서 실행되는 자바스크립트 함수다. 서버나 외부 API 호출 없이, 교차검증으로 확인한 라벨 데이터와 판정 기준값만 가지고 조건문과 배열 연산으로 동작한다.

05-1. Input Mapping Table

목표: 질문 유형별로 어떤 리뷰 신호를 찾고 어떤 형식으로 답할지 정의한다.

Input Mapping Table · 질문(인풋) → 리뷰 신호 → 답변 형식(아웃풋)

질문 유형 (인풋)	리뷰에서 찾는 신호	출력 형식 (아웃풋)
“시험기간에도 조용해?” · 맥락 / 의견형	시간 표현 + 소음 · 혼잡 언급 리뷰 조각 3개 이상	근거 리뷰 수 + 긍정 / 부정 비율 + 의견 갈림 여부 명시
“주차장 있어?” · 사실 확인형	주차 키워드가 포함된 리뷰 조각 1개 이상	유무 확정 답변 + “리뷰 N개 중 M개 근거” 뱃지

몰입환경은 왜 다른 클래스와 겹쳤나

① 지적받은 문제

몰입환경 안에 이미 소음이나 시설 이야기가 들어가 있는 것 아니냐는 지적을 받았다. > 판단이 모호해지는 문제 발생

② 데이터로 확인한 결과

3모델 교차검증에서 판단이 같린 **26건** 중 **23건(88.5%)**이 몰입환경이 낀 경우였다 (교차검증 상세는 05). 예 : '쾌적하다' → 몰입환경 ↔ 시설 / '분위기가 조용하다' → 몰입환경 ↔ 소음

③ 원인

혼잡도 · 소음 · 시설 · 운영시간은 리뷰에 나와있는 ‘대상’ 으로 읽히고, 몰입환경은 '그래서 공부가 잘 되는가'와 같이 원인에 인한 결과에 가깝다. 원인과 결과를 같은 맥락으로 분류하게 시켜서 판단 오류가 발생했다.

④ 수정사항

조각 (분절 문장) 에 대상을 가리키는 명사(자리 · 조명 · 음악 · 사람 등)가 있으면 우선 해당 클래스로 먼저 보내고, 대상 없이 느낌만 말한 부분만 몰입환경에 남긴다. 이 규칙을 적용하니 갈렸던 사례가 모두 한 곳으로 결정됐다.


클래스 에러 진단 참고 문헌 — Krippendorff, K. (2018). Content Analysis: An Introduction to Its Methodology (4th ed.). SAGE.

산출물 · User Flow · Task Flow · Storyboard

06. UX 시나리오 설계

목표: AI 기반 사용자 경험 흐름을 설계한다.

USER FLOW · 사용자 관점



TASK FLOW · 시스템 관점




AI 입력 → 시스템 → 사용자 피드백 : 자유 질문 → 분류 · 판정 → 근거 리뷰 + 갈림 여부 제시

STORY BOARD

SCENE 1


질문 입력



추천 질문 칩을 눌러도 되고, 방문 전 궁금한 점을 문장 그대로 입력해도 된다.

SCENE 2


유형 판정 · 근거 검색



질문의 클래스와 사실형 / 맥락형을 판정하고, 질문 키워드와 겹치는 리뷰만 좁혀 고른다.

SCENE 3


확실 답변



최소 근거 개수를 넘으면 답변과 함께 「리뷰 6개 중 5개 근거」로 근거 수를 노출한다.

SCENE 4

의견 갈림 · 원문 확인




70:30 안쪽이면 갈림으로 표시하고, 비율 바와 원문 펼침으로 직접 판단하게 한다.

산출물 · Feedback Mapping · State Diagram

07. AI 피드백 전략 설계

목표: AI 분석 결과를 사용자 경험으로 연결한다.

STATE DIAGRAM · 6개 상태



전환 방식 · 질문 전송 즉시 사용자 말풍선 추가 → AI 말풍선은 점 3개로 대기 → 같은 말풍선이 답변으로 교체(자리 이동 없음) → 원문 펼침은 아코디언, 대화는 그대로 누적

1 Feedback Mapping · AI 결과 → UI 피드백

대기	—■	인사 + 추천 질문 칩 3개 + 입력창
로딩	—■	사용자 말풍선을 먼저 붙이고 AI 말풍선은 점 3개
확실 답변	—■	답변 문장 + “리뷰 6개 중 5개 근거” 배지
의견 갈림	—■	⚠ 갈림 배지 + 긍정 / 부정 비율 바 + 원문 펼치기
정보부족	—■	기준 미만임을 알리고 답할 수 있는 질문을 제안
이해실패	—■	스터디카페 관련 질문으로 다시 쓰도록 예시 제시
위치 질문	—■	리뷰를 조회하지 않고 네이버지도 링크로 바로 답변

2 확정 기준값


의견 갈림 판단	70 : 30
최소 근거 · 사실 확인형	리뷰 1개
최소 근거 · 맥락 / 의견형	리뷰 3개 이상
다수결 모델 수	3개 (GPT · Claude · Gemini)
내 리뷰 신뢰도 판정	70 / 30 동일 기준

사실 정보는 리뷰 1개로도 검증되지만 주관적 판단은 표본이 적으면 갈림 여부 자체를 왜곡한다. 그래서 최소 근거를 클래스 단위가 아니라 질문 단위로 판정한다.

08. UI / 인터페이스 디자인

목표: AI 기반 인터페이스를 시각적으로 구현한다.

산출물 · 화면 7종 · 컴포넌트 정의



대기 화면 · 375 × 812

A 챗 헤더

← 뒤로가기와 매장명(단디스터디카페 전농점)을 고정 노출해, 지금 어느 매장 리뷰를 보고 있는지 항상 알 수 있게 했다.

B 세그먼트 탭

「리뷰 물어보기 / 내 리뷰 추가하기」 두 탭으로 나눠, 읽는 기능과 쓰는 기능을 같은 화면에서 전환한다.

C 추천 질문 칩

처음 온 사용자가 무엇을 물어볼 수 있는지 3개 예시로 보여준다. 칩을 그대로 눌러도 바로 질문이 전송된다.

D AI 말풍선 + 근거 뱃지

답변 문장 아래에 “리뷰 6개 중 5개 근거”처럼 근거 리뷰 수를 항상 붙인다. 답이 어디서 나왔는지를 사용자가 매번 확인할 수 있게 하는 것이 이 화면의 핵심이다.

E 의견 갈림 뱃지 + 비율 바

70:30 기준 안쪽이면 △ 의견 갈림 뱃지를 먼저 띄우고, 긍정 / 부정을 색으로 나눈 비율 바와 개수 (여유 5 · 붐뮴 3)를 함께 보여준다.

F 리뷰 원문 카드

답변의 근거가 된 리뷰를 원문 그대로, 상대 날짜(“3일 전 · 방문자 리뷰”)와 함께 펼쳐 보여준다. 내부에서는 분절된 조각으로 검색하지만, 화면에 노출하는 문장은 분절 전 원본을 쓴다.

디자인 톤 · 컴포넌트

배경 #17171C · 포인트 #3FA57A(민트) · 카드형 UI · Noto Sans KR

화면 7종 : 대기 · 로딩 · 확실 답변 · 의견 갈림 · 원문 펼침 · 누적 대화 · 정보부족 / 이해실패

컴포넌트 : 말풍선(사용자 / AI) · 근거 뱃지 · 비율 바 · 리뷰 원문 카드 · 추천 질문 칩 · 세그먼트 탭

08-1. 답변 상태 판정과 화면 비교


목표: 같은 질문 화면이 근거의 양과 비율에 따라 어떤 상태로 갈라지는지 정리한다.

산출물 · State 정의 6종 · 상태 판정 로직

1 답변 상태 판정 로직



2 실제 화면 비교



08-2. Interaction 설계 & Prototype 제작


목표: AI가 답을 못 찾을 때도 흐름이 끊기지 않도록 인터랙션을 설계한다.

산출물 · Interaction 설계 · Prototype

ANSWER DETAIL · 말풍선 확대


1 리뷰 원문 펼치기	
트리거	답변 카드 하단 “리뷰 원문 보기 ▼” 탭
동작	아코디언으로 아래로 펼침 · 이전 대화는 그대로 누적
내용	긍정 · 부정 그룹별 리뷰 원문 카드 + 상대 날짜
원칙	검색은 분절 조각 기준, 화면 노출은 분절 전 원문 기준

2 내 리뷰 추가하기 (추가 기능)	
트리거	홈 상단 세그먼트 탭에서 “내 리뷰 추가하기”로 전환
판정	GPT · Claude · Gemini가 각각 긍정 확률(0~100)을 매기고 평균을 낸다
기준	평균 70 이상 긍정 · 30 이하 부정 · 사이는 판단보류 (Q&A 갈림 기준과 동일)
표시	톤 뱃지 + 퍼센티지 바 — 예) 긍정 75% · GPT 82 · Claude 75 · Gemini 68
반영	등록 즉시 리뷰 풀에 추가되고, 5개 클래스 중 하나로 분류돼 이후 질문의 근거로 쓰인다



확실 답변 · 근거 리뷰 수 뱃지

답변 문장 아래 「리뷰 6개 중 5개 근거」를 항상 붙인다



원문 펼침 · 근거 리뷰 원문 카드

긍정 · 부정 그룹으로 나눠 상대 날짜와 함께 펼친다

TRANSITION

1 질문 전송 → 로딩

사용자 말풍선이 먼저 붙고, AI 말풍선은 점 3개 상태로 대기한다.

2 로딩 → 답변

0.9~1.4초 뒤 같은 말풍선이 답변으로 교체된다 (자리 이동 없음).

3 답변 → 원문 펼침

근거 카드가 아래로 펼쳐지고, 이전 대화는 그대로 남는다.


08-3. Screen Flow · 설계한 화면 7종

산출물 · Screen Flow

목표: 질문 입력부터 근거 원문 펼침까지 화면이 어떻게 이어지는지 보여준다.

SCREEN FLOW

설계한 화면 7종 : 대기 · 로딩 · 확실 답변 · 의견 갈림 · 원문 펼침 · 누적 대화 · 정보부족 / 이해실패 (의견 갈림 · 정보부족 / 이해실패는 08-1 참고)



09. AI-UI 연동 구현

목표: AI 모델과 인터페이스를 실제로 연결한다.

산출물 · 실행 가능한 Demo (React + Vite · 375 × 812)

전체 연동 흐름 · 상태 변화 구현

1 연동 시도와 전환

Figma 디자인

화면 7종 시안 완성

Framer 연동

연동이 원활하지 않아 중단

Claude Code 프로토타입

브라우저에서 바로 실행

실제 LLM API를 호출하지 않고, 교차검증으로 확정한 라벨 데이터와 판정 로직만으로 동작하도록 구현했다.

4 프로토타입 동작 확인

- ✓ 5개 클래스 질문이 모두 매칭되는가
- ✓ 사실형 질문(주차장 · 운영시간)이 리뷰 1개로 답하는가
- ✓ 맥락형 질문이 3개 미만일 때 정보부족으로 빠지는가
- ✓ 70:30 경계에서 갈림 / 확실이 바뀌는가
- ✓ 원문 펼침이 분절 전 원본 문장을 보여주는가
- ✓ 위치 질문이 네이버지도 링크로 답하는가
- ✓ 내 리뷰 등록이 즉시 반영되는가

2 답변 생성 로직 · Prediction과 UI 연결

클래스 분류

질문 키워드가 5개 클래스 중 어디에 걸리는지 점수로 판단

질문 유형 판정

시설은 질문 키워드로 사실형 / 맥락형을 나누고, 나머지는 클래스 기본값

근거 좁히기

질문 단어와 겹치는 리뷰 조각만 남긴다

상태 결정

최소 개수(1 / 3개)와 70:30 기준으로 확실 · 갈림 · 정보부족을 결정

문장 생성

“리뷰 6개 중 5개가 긍정적인 의견이었어요”처럼 개수를 넣어 출력

3 실패 처리 방식

사실형 질문에 겹치는 리뷰가 없으면 클래스 전체를 근거로 대체하지 않고 “정보부족”으로 답한다.

그러지 않으면 주차장 질문에 사물함 리뷰가, 마감시간 질문에 방학 단축운영 리뷰가 근거로 둔갑한다. 다만 운영시간 · 위치 질문은 리뷰가 없어도 네이버지도 링크를 함께 제공해 흐름이 끊기지 않게 했다.

질문 입력



클래스 분류



질문 유형 판정 (사실 / 맥락)



근거 리뷰 좁히기



최소 개수 · 70:30 판정



답변 상태 결정



화면 렌더링

10. 사용성 평가 및 개선

목표: 사용성을 평가하고 인터페이스를 개선한다.

산출물 · 사용성 평가 결과 · 최종 개선안

1 사용자 테스트 (1차 자체 테스트)

별도 사용자 테스트 이전 단계로, 직접 프로토타입을 사용하며 1차 자체 테스트를 진행했다. 실제로 물어볼 만한 질문을 던져 답변 커버리지를 확인했다.

테스트 질문

“몇 시까지 해?”

“주차장 있어?”

“시험기간에도 조용해?”

“2층이랑 4층 중 어디가 조용해?”

평가 항목

● 분류 정확도

● 근거 신뢰성

● 상태 전환 이해도

● 사용 편의성

3 직관성 및 만족도 평가 (자체 관찰 기록)

직관성

근거 리뷰 수 배지 덕분에 답변의 출처를 바로 이해할 수 있었다

신뢰감

의견 알림 표시가 있으면 “직접 확인해봐야겠다”는 판단으로 이어졌다

만족도

리뷰가 적어 답변이 단조롭고 알게 느껴졌다 — “정보가 부족하다”는 인상

커버리지

“몇 시까지 해?”에 답하지 못했다 (해당 클래스가 없었다)

판단 기준

“주차장 있어?” 같은 사실 확인형이 3개 기준에 막혀 정보부족으로 처리됐다

2 인식을 (분류 정확도) 평가

3모델 톤 만장일치 (372조각)

100% · 갈림 0건

분류 정확도 (테스트 문장 45개)

45 / 45 정확 분류

100%

3모델 클래스 만장일치 · 문장 단위

1차 · 300문장

90.0%

3모델 클래스 만장일치 · 조각 단위

2차 · 372조각 · 개선

93.0%

4 개선안 도출

데이터 부족

❌ 초기 240문장 → 5개 클래스 300문장 (클래스당 60문장)

운영시간 답변 불가

❌ 운영시간 클래스 신규 추가 (4 → 5개)

클래스 경계 모호

❌ 문장 분절 + 3모델 다수결 (불일치 10.0% → 7.0%)

사실형 질문이 정보부족

❌ 최소 근거를 질문 단위로 분리 (사실 1개 / 맥락 3개)

톤 이분법 판정

❌ 3모델 긍정확률 평균 방식 (70 / 30 기준 통일)

CONCLUSION

목표: 이번 프로젝트에서 무엇이 바뀌었고 무엇이 남았는지 정리한다.

리뷰 기반 AI 챗봇은 요약이 아니라,
질문에 답하고 근거를 드러내 판단을 돕는 도구다.

근거를 밝히는 답변

갈리면 갈렸다고 말하는 정직함

숫자로 고정한 판단 기준



1 문제 → 원인 → 재설계를 세 번 반복했다

톤 판단이 주관적이다 → 3모델 다수결
갈림의 원인이 문장에 있다 → 의미 단위 분절
클래스 단위 기준이 안 맞는다 → 질문 단위 기준

2 숫자로 남은 결과

분류 정확도 45 / 45 · 톤 일치 **100%** · 클래스 불일치 **10.0% → 7.0%**
판단보류 **0건** · 답변 데이터 **300문장** · 클래스 **5개**
확정 기준값 **70:30** · 최소 근거 **1개 / 3개**

3 남은 과제

“쾌적하다”, “분위기”, “음악” 계열 표현은 분절 후에도 시설 · 몰입환경 · 소음 경계에
서 걸린다. 클래스 정의 문구를 더 다듬어야 할 지점으로 기록했다.

최종 산출물

실행 가능한 리뷰 챗봇 프로토타입 (React + Vite · 375 × 812) + 3모델 교차검증으로 확인한 라벨 데이터(300문장 → 372조각) + 5개 클래스 300문장 답변 데이터셋